

SVEUČILIŠTE U SPLITU  
PRIRODOSLOVNO-MATEMATIČKI FAKULTET

UVOD U UMJETNU INTELIGENCIJU

Seminarski rad

PRIMJENA NEURONSKIH MREŽA U ANALIZI SENTIMENTA

Maksimilijan Katavić

12. veljače 2025.

## Sadržaj

1	UVOD .....	1
1.1	Što je analiza sentimenta? .....	1
1.2	Područja primjene analize sentimenta.....	1
2	TEORIJSKA PODLOGA .....	2
2.1	Osnovni pristupi implementaciji analize sentimenta .....	2
2.2	Neuronske mreže i njihovo funkcioniranje .....	2
2.3	Modeli koji koriste leksički pristup u analizi sentimenta.....	2
2.3.1	VADER (Valence Aware Dictionary and sEntiment Reasoner).....	3
2.4	Modeli koji koriste neuronske mreže u analizi sentimenta.....	3
2.4.1	RoBERTa (Robustly optimized BERT approach) .....	3
2.4.2	Hugging Face pipeline.....	3
3	KORIŠTENI PODATCI .....	4
4	PRIMJENA LEKSIČKOG PRISTUPA U ANALIZI SENTIMENTA .....	5
4.1	Osnove NLTK-a.....	5
4.2	VADER.....	6
5	PRIMJENA NEURONSKIH MREŽA U ANALIZI SENTIMENTA .....	9
5.1	RoBERTa .....	9
5.2	Hugging Face pipeline (DistilBERT) .....	12

## 1 UVOD

### 1.1 Što je analiza sentimenta?

Analiza sentimenta (*eng. sentiment analysis*) proces je kojim se određuje ima li tekst pozitivan, negativan ili neutralan sentiment. Ovaj proces koristi tehnike obrade prirodnog jezika (NLP) u svrhu analize riječi, fraza i konteksta u kojima se pojavljuju. Analiza sentimenta je danas bitna iz razloga što različitim organizacijama pruža mogućnost boljeg razumijevanja stavova korisnika, potrošača ili javnosti prema nekom događaju, usluzi ili proizvodu. To pomaže donijeti informirane poslovne odluke, unaprijediti proizvode ili usluge te povećati zadovoljstvo korisnika.

### 1.2 Područja primjene analize sentimenta

Analiza sentimenta ima široku primjenu u različitim područjima, a pogotovo je korisna u industrijama u kojima je povratna informacija korisnika bitna. Neka od područja primjene su:

- **Društvene mreže:** Analiza objava i komentara na društvenim mrežama kao što su X, Instagram i Facebook omogućuje brzu procjenu javnog mišljenja o određenim temama, proizvodima (brendovima) ili događajima. Analiza sentimenta pomaže tvrtkama da u realnom vremenu prepoznaju probleme ili dobiju neku drugu vrstu važne informacije.
- **Recenzije proizvoda:** Potrošači ostavljaju svoje recenzije po online trgovinama i forumima. Ova vrsta analize pomaže tvrtkama da bolje i brže razumiju mišljenja svojih kupaca o svojim proizvodima ili uslugama, što im onda omogućuje i brže reagiranje i prilagodbu ponude.
- **Financijska analiza:** Investitori i financijski analitičari koriste analizu sentimenta kako bi predvidjeli kretanje cijena dionica. To rade tako da računaju sentiment vijesti, financijskih izvještaja ili mišljenja analitičara. U novije vrijeme, s porastom takozvanih *retail trader*-a sve bitnije postaje i praćenje objava i komentara na financijskim internet forumima kao što je npr. *Wall Street Bets* na Reddit-u.
- **Politika i javno mnijenje:** Politolozi i politički analitičari koriste analizu sentimenta za praćenje i bolje razumijevanje stavova birača, društvenih pokreta ili pak reakcija na političke događaje. Primjer ovoga bi bio da neki političar objavi neku kontroverznu objavu te da se zatim pomoću analize sentimenta korištene sa mrežnom analizom dobije bolje razumijevanje toga kako se taj sentiment širi te kako se formiraju "klasteri" sličnih mišljenja.

## 2 TEORIJSKA PODLOGA

### 2.1 Osnovni pristupi implementaciji analize sentimenta

Postoje tri osnovna pristupa u implementaciji analize sentimenta:

1. **Leksički pristup** temelji se na korištenju unaprijed definiranih rječnika koji sadrže emocionalne vrijednosti riječi. Svim riječima u rječniku je dana pozitivna ili negativna konotacija. Ova vrsta pristupa je jednostavna, ali ima svoja ograničenja kao što su razumijevanje konteksta ili ironije.
2. **Strojno učenje (Machine Learning)** je vrsta pristupa u kojoj se koriste algoritmi za prepoznavanje uzoraka u podacima. Modeli poput Naivnog Bayesa, Support vector machine-a ili Random forest-a koriste skupove podataka za učenje kako bi razlikovali pozitivne, negativne i neutralne riječi ili fraze.
3. **Duboko učenje (Deep Learning)** je pristup koji uključuje korištenje neuronskih mreža koje mogu učiti napredne načine predstavljanja informacija, čime postižu veću preciznost u analizi sentimenta. U kontekstu analize sentimenta, napredni način predstavljanja informacija ili složena reprezentacija podrazumijeva način predstavljanje podataka koji omogućuje modelima da prepoznaju dublje veze između podataka. To je ono što jednostavniji modeli koji koriste bag-of-words pristup ne mogu postići.

### 2.2 Neuronske mreže i njihovo funkcioniranje

Duboko učenje se temelji na neuronskim mrežama. Neuronske mreže oponašaju način funkcioniranja ljudskog mozga u procesu obrade informacija. Osnovna građevna jedinica neuronske mreže je neuron. Svaki neuron je raspodijeljen u neki od slojeva (ulazni, skriveni ili izlazni sloj), a svaki sloj te neuroni u njemu imaju istu aktivacijsku funkciju (npr. sigmoidna, ReLU, tanh, softmax). Svaki neuron obavlja određenu funkciju obrade podataka. Nakon obrade neuron prosljeđuje naprijed neuronima u višim slojevima svoju numeričku vrijednost.

### 2.3 Modeli koji koriste leksički pristup u analizi sentimenta

Ako postoji ograničenje resursa u smislu da nije dostupan bolji hardware, ako je analizu potrebno napraviti brzo ili ako nije potrebna izvrsna preciznost, leksički modeli mogu biti odličan odabir u analizi sentimenta.

### **2.3.1 VADER (*Valence Aware Dictionary and sEntiment Reasoner*)**

VADER je leksički pristup analizi sentimenta koji se temelji na rječniku riječi i njihovim emocionalnim vrijednostima. Ovaj model je osobito koristan za analizu kratkih tekstova i komentara na društvenim mrežama jer uzima u obzir specifičnosti jezika na mrežama, poput upotrebe skraćenica, interpunkcije i emotikona. VADER koristi unaprijed definirane liste riječi s određenim vrijednostima sentimenta, a zatim kombinira te vrijednosti kako bi odredio ukupni sentiment teksta. Ova vrsta pristupa se zove i bag-of-words. Iako je jednostavan, VADER je vrlo učinkovit za društvene mreže i slične tekstove.

## **2.4 Modeli koji koriste neuronske mreže u analizi sentimenta**

Ovisno o složenosti zadataka i vrsti podataka u analizi sentimenta se koriste različiti modeli koji koriste neuronske mreže. Neke od poznatijih modela i pristupa su:

### **2.4.1 RoBERTa (*Robustly optimized BERT approach*)**

RoBERTa je napredni transformer-based jezični model temeljen na BERT-u (Bidirectional Encoder Representations from Transformers). RoBERTa optimizira BERT-ov pristup učenja prepoznavanja jezika, čineći ga preciznijim i sposobnijim u analizi sentimenta. Prije svega, RoBERTa je trenirana na puno većoj količini podataka (čak 10 puta većoj). Uz to, RoBERTa za razliku od BERT-a ne koristi NSP (Next Sentence Prediction) iz razloga što su istraživanja pokazala da s NSP-em ili bez njega nema veće promjene performansi. Također, RoBERTa koristi puno veće batch-eve od BERT-a. Uz to, BERT koristi fiksni postotak (15%) maskiranih tokena u svakom batch-u, dok RoBERTa dinamički mijenja uzorak maskiranja za svaku epohu te tako pomaže modelu da vidi širi raspon maskiranih tokena.

### **2.4.2 Hugging Face pipeline**


Hugging Face je platforma koja omogućava jednostavnu primjenu unaprijed treniranih modela za analizu sentimenta, uključujući BERT, RoBERTa i mnoge druge. Korištenjem Hugging Face pipeline-a, korisnici mogu brzo implementirati modele za analizu sentimenta bez potrebe za dubokim tehničkim znanjem.

### 3 KORIŠTENI PODATCI

Skup podataka koji se koristi je Women's E-Commerce Clothing Reviews. Skup sadrži recenzije ženske odjeće iz e-trgovina. Podatci obuhvaćaju približno 20.000 recenzija.

Podatci uključuju:

- ID odjeće: Cjelobrojna kategorijska varijabla koja se odnosi na određeni komad odjeće koji se recenzira.
- Dob: Pozitivna cjelobrojna varijabla koja označava dob recenzenta.
- Naslov: Tekstualna varijabla koja predstavlja naslov recenzije.
- Tekst recenzije: Tekstualna varijabla koja sadrži tekst recenzije.
- Ocjena: Pozitivna cjelobrojna varijabla koja označava ocjenu proizvoda koju je kupac dodijelio, gdje 1 označava najlošiju ocjenu, a 5 najbolju.
- Preporuka: Binarna varijabla koja pokazuje preporučuje li kupac proizvod (1 - preporučuje, 0 - ne preporučuje).
- Broj pozitivnih povratnih informacija: Pozitivna cjelobrojna varijabla koja bilježi broj drugih kupaca koji su ovu recenziju ocijenili korisnom.
- Naziv odjela: Kategorijska varijabla koja označava naziv visokorazinske podjele proizvoda.
- Naziv odsjeka: Kategorijska varijabla koja označava naziv odsjeka proizvoda.
- Naziv klase: Kategorijska varijabla koja označava naziv klase proizvoda.



Možemo vidjeti da je većina recenzija s 5 zvjezdica. Prema manjem broju zvjezdica broj recenzija pada. Iz ovoga se može zaključiti da je skup podataka jako pristran ka pozitivnim recenzijama, što je dobro za znati prije nastavka analize.

## 4 PRIMJENA LEKSIČKOG PRISTUPA U ANALIZI SENTIMENTA

### 4.1 Osnove NLTK-a

Prije korištenja neuronskih mreža i naprednijih modela za analizu sentimenta dobro je proći kroz osnove NLTK-a tj. Natural Language Toolkit-a. Kao primjer uzeta je 3. recenzija. To je recenzija:

*I had such high hopes for this dress and really wanted it to work for me. i initially ordered the petite small (my usual size) but i found this to be outrageously small. so small in fact that i could not zip it up! i reordered it in petite medium, which was just ok. overall, the top half was comfortable and fit nicely, but the bottom half had a very tight under layer and several somewhat cheap (net) over layers. imo, a major design flaw was the net over layer sewn directly into the zipper - it c*

Jedna od stvari koje NLTK nudi je funkcija `word_tokenize()` koja se koristi za tokenizaciju teksta. Tokenizacija je proces razdvajanja teksta na manje jedinice (tokene) kao što su riječi, interpunkcijski znakovi ili druge jezične jedinice. Kada se recenzija koje je uzeta kao primjer tokenizira dobije se niz tokena:

`['I', 'had', 'such', 'high', 'hopes', 'for', 'this', 'dress', 'and', 'really', 'wanted', 'it', 'to', 'work', 'for', 'me', '.', 'i', 'initially', 'ordered', 'the', 'petite', 'small', '(', 'my', 'usual', 'size', ')', 'but', 'i', 'found', 'this', 'to', 'be', 'outrageously', 'small', '.', 'so', 'small', 'in', 'fact', 'that', 'i', 'could', 'not', 'zip', 'it', 'up', '!', 'i', 'reordered', 'it', 'in', 'petite', 'medium', ',', 'which', 'was', 'just', 'ok.', 'overall', ',', 'the', 'top', 'half', 'was', 'comfortable', 'and', 'fit', 'nicely', ',', 'but', 'the', 'bottom', 'half', 'had', 'a', 'very', 'tight', 'under', 'layer', 'and', 'several', 'somewhat', 'cheap', '(', 'net', ')', 'over', 'layers', '.', 'imo', ',', 'a', 'major', 'design', 'flaw', 'was', 'the', 'net', 'over', 'layer', 'sewn', 'directly', 'into', 'the', 'zipper', '-', 'it', 'c']`

Još jedna od stvari koju NLTK nudi je funkcija `pos_tag()` koja služi za prepoznavanje vrste riječi (part of speech) tj. pridodavanje oznaka svakom tokenu. Za primjer bi to izgledalo ovako:

`[('I', 'PRP'), ('had', 'VBD'), ('such', 'JJ'), ('high', 'JJ'), ('hopes', 'NNS'), ('for', 'IN'), ('this', 'DT'), ('dress', 'NN'), ('and', 'CC'), ('really', 'RB'), ('wanted', 'VBD'), ('it', 'PRP'), ('to', 'TO'), ('work', 'VB'), ('for', 'IN'), ('me', 'PRP'), ('.', '.'), ('i', 'VB'), ('initially', 'RB'), ('ordered', 'VBD'), ('the', 'DT'), ('petite', 'JJ'), ('small', 'JJ'), ('(', '('), ('my', 'PRP$'), ('usual', 'JJ'), ('size', 'NN'), (',', ','), ('but', 'CC'), ('i', 'JJ'), ('found', 'VBD'), ('this', 'DT'), ('to', 'TO'), ('be', 'VB'), ('outrageously', 'RB'), ('small', 'JJ'), ('.', '.'), ('so', 'RB'), ('small', 'JJ'), ('in', 'IN'), ('fact', 'NN'), ('that', 'IN'), ('i', 'NN'), ('could', 'MD'), ('not', 'RB'), ('zip', 'VB'), ('it', 'PRP'), ('up', 'RP'), ('!', '!'), ('i', 'NN'), ('reordered', 'VBD'), ('it', 'PRP'), ('in', 'IN'), ('petite', 'JJ'), ('medium', 'NN'), (',', ','), ('which', 'WDT'), ('was', 'VBD'), ('just', 'RB'), ('ok.', 'JJ'), ('overall', 'JJ'), (',', ','), ('the', 'DT'), ('top', 'JJ'), ('half', 'NN'), ('was', 'VBD'), ('comfortable', 'JJ'), ('and', 'CC'), ('fit', 'JJ'), ('nicely', 'RB'), (',', ','), ('but', 'CC'), ('the', 'DT'), ('bottom', 'JJ'), ('half', 'NN'), ('had', 'VBD'), ('a', 'DT'), ('very', 'RB'),`

*('tight', 'JJ'), ('under', 'IN'), ('layer', 'NN'), ('and', 'CC'), ('several', 'JJ'), ('somewhat', 'RB'), ('cheap', 'JJ'), ('(', '('), ('net', 'JJ'), (',', ','), ('over', 'IN'), ('layers', 'NNS'), ('.', '.'), ('imo', 'NN'), (';', ';'), ('a', 'DT'), ('major', 'JJ'), ('design', 'NN'), ('flaw', 'NN'), ('was', 'VBD'), ('the', 'DT'), ('net', 'JJ'), ('over', 'IN'), ('layer', 'NN'), ('sewn', 'NN'), ('directly', 'RB'), ('into', 'IN'), ('the', 'DT'), ('zipper', 'JJR'), ('-', '-'), ('it', 'PRP'), ('c', 'VBD'))*

Vidljivo je da je npr. riječ *dress* označena kao NN, što u označavanju vrste riječi znači da je to imenica u jednini. Za značenje ostatka oznaka pogledati u literaturu.

Korak dalje od do sada napravljenog bi bilo uzeti dobivene oznake vrste riječi te ih pretvoriti u entitete. U NLTK-u se može primijeniti chunking, a zatim NE chunking (Named Entity Chunking). Ovaj proces koristi named entity chunk-er kako bi grupirao zadani popis tokena u veće cjeline teksta tj. u smislene segmente. Pošto je gore navedeni primjer velik, a ne bi dobro prikazao što se radi u NE chunking-u naveden je novi primjer:

*Barack Obama was born in Hawaii.*

Tu nakon poziva dvije funkcije (`chunk` i `ne_chunk`) se dobije sljedeće:

*(S (PERSON Barack/NNP Obama/NNP) was/VBD born/VBN in/IN (GPE Hawaii/NNP) ./.)*

Može se vidjeti kako je Barack Obama prepoznat kao osoba, a Hawaii kao geopolitical entity.

## 4.2 VADER

VADER je skraćenica za Valence Aware Dictionary and Sentiment Reasoner. Ovaj pristup jednostavno uzima sve riječi u rečenici i svakoj od njih dodjeljuje vrijednost: pozitivnu, negativnu ili neutralnu. Zatim ih kombinira kroz matematičku jednadžbu i na temelju svih riječi u rečenici izračunava koliko je izjava pozitivna, negativna ili neutralna. Jedna stvar koju treba imati na umu je da ovaj pristup ne uzima u obzir odnose između riječi, što je vrlo važno u ljudskom govoru. No, barem predstavlja dobar početak. Također uklanja nešto što se zove *stop words*. To su riječi poput *and*, *the* i sličnih koji nemaju pozitivno ili negativno značenje, već samo služe za strukturu rečenice. Kako bi se započelo sa korištenjem VADER-a potrebno je uvesti klasu `SentimentIntensityAnalyzer` iz `nlk.sentiment` modula. Ova klasa je ključan alat za analizu sentimenta pomoću VADER-a. Zatim je potrebno napraviti instancu `SentimentIntensityAnalyzer` klase. Tu instancu se može zamisliti kao alat za analizu sentimenta, spreman za upotrebu. Kada se uz tu instancu iskoristi funkcija `polarity_scores` za recenziju koja je uzeta za primjer dobije se:

*{'neg': 0.027, 'neu': 0.792, 'pos': 0.181, 'compound': 0.9427}*


Vidi se iz dobivenih rezultata da je VADER odredio da je sentiment recenzije pozitivan, što nije točno. Međutim jasno je zašto je model tako izračunao. To je zato jer negativni sentiment nije



izražen nekim specifičnim riječima već više skupom riječi od kojih skoro ni jedna sama po sebi nema negativan sentiment. S druge strane, za ono malo pozitivnog sentimenta su baš korištene riječi koje imaju same po sebi pozitivan sentiment. Ovaj primjer pokazuje savršeno sve manjkavosti ovog modela koji se temelji na bag-of-words pristupu.


Općenito, vrijedi da je sentiment pozitivan ako je  $\text{compound} \geq 0.05$ , neutralan ako je  $-0.05 < \text{compound} < 0.05$ , a negativan ako je  $\text{compound} \leq -0.05$ . Kako se računaju pos, neu, neg i compound najbolje je pročitati u literaturi.

Može se pretpostaviti da ako je ocjena koju je recenzent dao pet zvjezdica, tekst recenzije će vjerojatno biti pozitivniji nego ako je ocjena bila jedna zvjezdica.



Iz grafa se vidi da recenzije s jednom zvjezdicom imaju niži compound score, dok recenzije s pet zvjezdica imaju viši score, što je bilo očekivano. Što je viša ocjena, to tekst postaje pozitivniji. Ovo je dobro jer potvrđuje da model pravilo procjenjuje sentiment recenzija.

Ovaj graf se može razbiti, pa se umjesto compound-a dobiju tri grafa. Jedan za pos, jedan za neu i jedan za neg.



Iz grafova se može iščitati da *pozitivno* raste kako ocjena u zvjezdicama raste, da *neutralno* ostaje uglavnom ravno, a da *negativno* pada i postaje manje negativno kako ocjena zvjezdica raste. Ovo potvrđuje ono što je bilo očekivano i pokazuje da VADER ima vrijednost u povezivanju ocjene teksta i rezultata sentimenta, te da su te dvije stvari povezane.

Dobar način za pronalazak vjerojatnih pogrešaka je da se pronađu recenzije koje imaju jednu zvjezdicu ali im je VADER dao visoki pozitivan sentiment, ili recenzije koje imaju 5 zvjezdica ali im je VADER dao visoki negativan sentiment. Neki primjeri su:

*I was very excited to order this top in red xs. so cute, but it was huge, shapeless and support thin! it had to go back. i should've looked at other reviews.*

Ovo je primjer gdje je identificiran pozitivan sentiment kod negativne ocjene. Model ovo interpretira kao pozitivnu izjavu, jer sadrži riječi poput "cute" i "excited". Međutim, budući da je korisnik ostavio 1 zvjezdicu, jasno je da je recenzija zapravo negativna. Ovo pokazuje kako VADER, koji koristi metodu bag-of-words, ne može prepoznati kontekstualne nijanse u rečenicama.

*Loved the green color, the cut is super flattering, but alas, i do need hte petite, ti was a bit long and i looked a little lost. unfrotuantely, the color is sold out in petite :-{*

Ovo je suprotan primjer gdje je identificiran negativan sentiment kod pozitivne ocjene. Ovo je zanimljivo jer rečenica sadrži negativan ton unatoč tome što je recenzija pozitivna (5 zvjezdica). U ovom slučaju ima argumenata da je model i dobro i loše izračunao sentiment. Argument da je pogriješio je očit, a to je da je ovo recenzija od 5 zvjezdica te kao takva ima pozitivan sentiment (koji je vidljiv na početku recenzije). A argument da je pogodio bi bio da je jednostavno prepoznao negativan sentiment unutar pozitivne recenzije.

## 5 PRIMJENA NEURONSKIH MREŽA U ANALIZI SENTIMENTA

### 5.1 RoBERTa

Prethodni model je gledao svaku riječ u rečenici tj. recenziji zasebno i ocjenjivao je pojedinačno. Ali, kao što je prije spomenuto, ljudski jezik jako ovisi o kontekstu. Npr. rečenica s negativnim riječima može biti sarkastična ili se može oslanjati na druge riječi koje je zapravo čine pozitivnom izjavom. VADER model ne može prepoznati takve odnose među riječima. Međutim, sve popularniji dubinski modeli temeljeni na transformatorima mogu. Kako bi se krenulo sa analizom sentimenta pomoću RoBERTa-e potrebno je samo nekoliko linija koda. Prvo, potrebno je iz `transformers` biblioteke uvesti `AutoTokenizer` i `AutoModelForSequenceClassification`. `AutoTokenizer` je alat koji služi za pretvaranje teksta u oblik koji model može razumjeti (numeričke vrijednosti umjesto slova i riječi). `AutoModelForSequenceClassification` je alat koji služi za učitavanje unaprijed treniranih modela, specifično modela za klasificiranje sekvenci (teksta). Ovaj alat tj. klasa automatski odabire potrebnu arhitekturu i konfiguraciju za odabrani unaprijed trenirani model. Nakon toga potrebno je odrediti model. Model koji će biti korišten u ovom projektu je `cardiffnlp/twitter-roberta-base-sentiment`. Ovaj model se temelji na RoBERTa-i i prilagođen je za analizu sentimenta na podacima sa Twittera. Zatim pomoću `AutoTokenizer`-a i funkcije `from_pretrained()` se dobiva unaprijed trenirani tokenizer prilagođen za ovaj model. Ukratko, nije potrebno znati koji tokenizer-a izabrati jer `AutoTokenizer` sam bira najpovoljniji za odabrani model. Na kraju, pomoću `AutoModelForSequenceClassification` i funkcije `from_pretrained()` se učitava model.

Za podsjetnik, VADER je za recenziju:

*I had such high hopes for this dress and really wanted it to work for me. i initially ordered the petite small (my usual size) but i found this to be outrageously small. so small in fact that i could not zip it up! i reordered it in petite medium, which was just ok. overall, the top half was comfortable and fit nicely, but the bottom half had a very tight under layer and several somewhat cheap (net) over layers. imo, a major design flaw was the net over layer sewn directly into the zipper - it c*

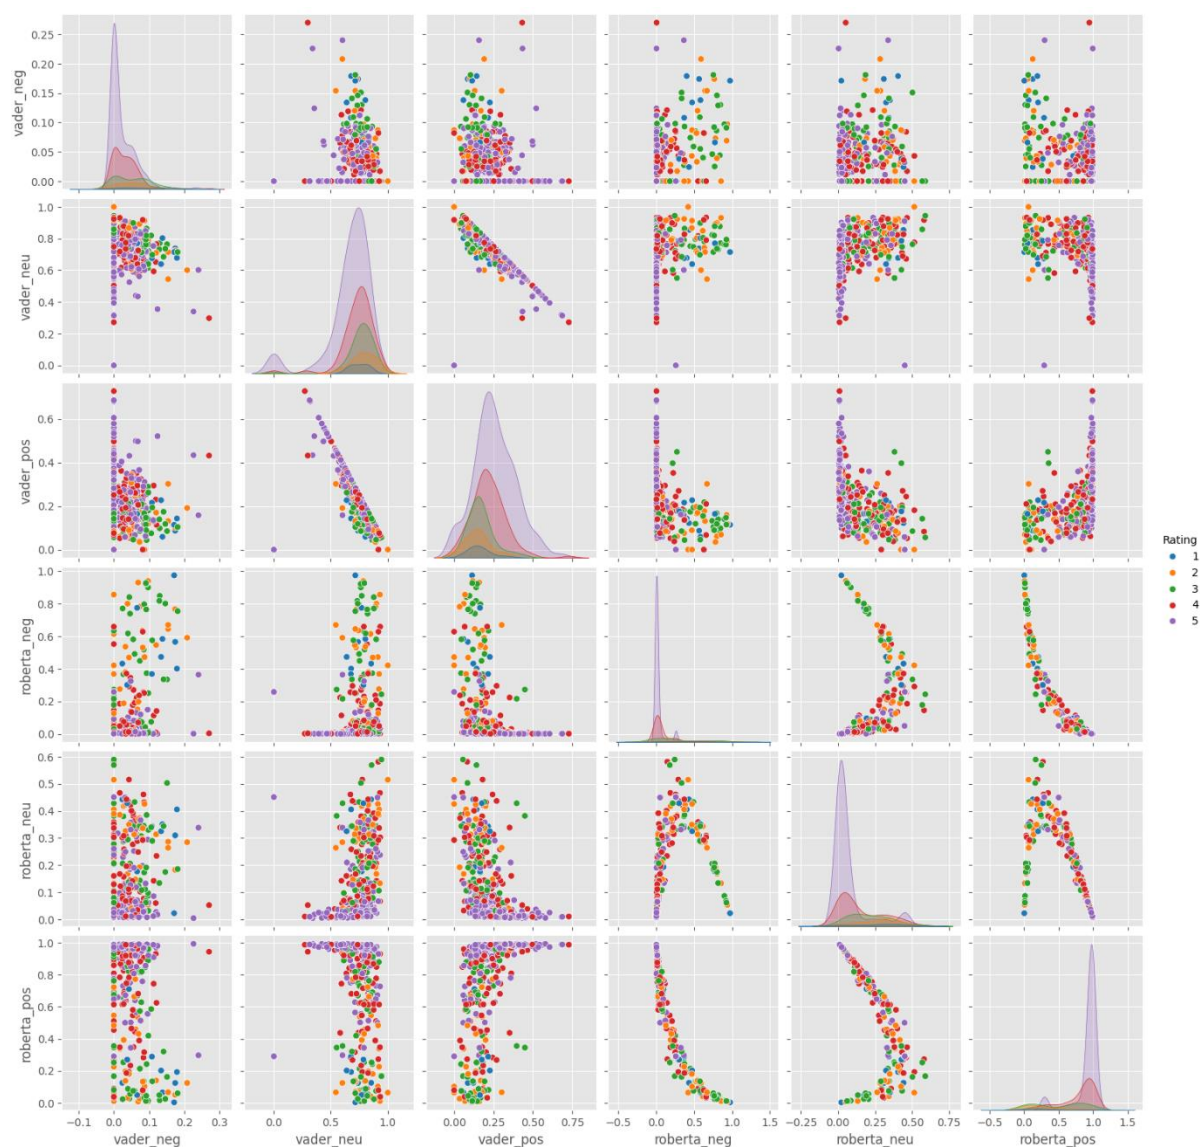
vratio:

```
{'neg': 0.027, 'neu': 0.792, 'pos': 0.181, 'compound': 0.9427}
```

Kada ista rečenica prođe kroz RoBERTa-u dobije se:

```
{'roberta_neg': 0.3668031, 'roberta_neu': 0.3801399, 'roberta_pos': 0.25305697}
```





Iz priložene vizualizacije se može nekoliko stvari zaključiti. Prvo, za VADER model se vidi da su pozitivnije recenzije pomaknute više udesno za recenzije s pet zvjezdica. U RoBERTa modelu je taj pomak udesno još izraženiji. Osim toga, vidljive su i određene korelacije između RoBERTa modela i VADER-a, iako na prvu nije sasvim jednostavno uočiti te odnose. Međutim, ono što se vrlo jasno vidi jest da je VADER model manje siguran u svoje prognoze u usporedbi sa RoBERTa modelom, koji puno jasnije razdvaja pozitivne, neutralne i negativne rezultate za svaku predikciju. Ako se pogleda malo detaljnije, RoBERTa model daje vrlo visoke ocjene za pozitivnost kod recenzija s pet zvjezdica, dok su recenzije s jednom zvjezdicom izrazito niske po pozitivnom sentimentu.

Kao i kod VADER-a, dobar način za pronalazak pogrešaka je da se pronadu recenzije koje imaju jednu zvjezdicu ali im je RoBERTa dala visoki pozitivan sentiment, ili recenzije koje imaju 5 zvjezdica ali im je RoBERTa dala visoki negativan sentiment.

Neki primjeri su:

*I was very excited to order this top in red xs. so cute, but it was huge, shapeless and support thin! it had to go back. i should've looked at other reviews.*

Model ovo prepoznaje kao pozitivan sentiment, ali stvarna ocjena recenzije je 1 zvjezdica. Vidi se da rečenica počinje pozitivno ("I was very excited ") i zatim prelazi u negativan ton ("it was huge, shapeless and support thin ").

*Loved the green color, the cut is super flattering, but alas, i do need hte petite, ti was a bit long and i looked a little lost. unfrotuantely, the color is sold out in petite :-{*

Ovo je zanimljiva rečenica iz dva razloga. Prvo, jer sadrži negativan ton unatoč tome što je recenzija pozitivna (5 zvjezdica). Drugo, jer sadrži velik broj tipfelera. Zanimljivo je da su oba modela (RoBERTa i VADER) identificirala ovu rečenicu kao negativnu, iako je recenzentica dala najvišu ocjenu. Može se reći da su se modeli zbunili, ali su možda i ispravno prepoznali negativan sentiment unutar pozitivne recenzije – što znači da su možda odradili bolji posao nego što bi se očekivalo.

## 5.2 Hugging Face pipeline (DistilBERT)

Kako bi se krenulo sa korištenjem pipeline-a dovoljno je uvesti iz transformers biblioteke pipeline te nakon toga u pipeline funkciju poslati *sentiment-analysis* i sve je spremno. Pošto, pri inicijalizaciji pipeline-a nije definiran model, odabran je DistilBERT, preciznije distilbert-base-uncased-finetuned-sst-2-english. DistilBERT (2019) sažima BERT u model sa samo 60% njegovih parametara (66 milijuna), dok zadržava 95% njegovih rezultata na referentnim testovima.

Za rečenicu:

*I love playing football!*

Model vraća:

```
[{'label': 'POSITIVE', 'score': 0.9997661709785461}]
```

Rečenica poslana modelu je pozitivna, te model vraća pozitivan rezultat sa visokom sigurnošću.

Za tekst:

booo

Model vraća:

```
[{'label': 'NEGATIVE', 'score': 0.9936267137527466}]
```

Tekst poslan modelu je negativna, te model vraća negativan rezultat sa visokom sigurnošću.

## Literatura

1. Wikipedia (n.d.). Sentiment Analysis [Encyclopedia Article]. [https://en.wikipedia.org/wiki/Sentiment\\_analysis](https://en.wikipedia.org/wiki/Sentiment_analysis)
2. nicapotato (2018). Women's E-Commerce Clothing Reviews [Dataset]. <https://www.kaggle.com/nicapotato/womens-ecommerce-clothing-reviews>
3. Natural Language Toolkit (NLTK) (n.d.). NLTK: Natural Language Processing with Python [Software]. <https://www.nltk.org/>
4. University of Pennsylvania (2003). Penn Treebank POS Tagging [Dataset]. [https://www.ling.upenn.edu/courses/Fall\\_2003/ling001/penn\\_treebank\\_pos.html](https://www.ling.upenn.edu/courses/Fall_2003/ling001/penn_treebank_pos.html)
5. 2. Hutto, C.J. (2014). VADER: A Parsimonious Rule-based Model for Sentiment Analysis [Software]. <https://github.com/cjhutto/vaderSentiment>
6. Hugging Face (n.d.). RoBERTa Model Documentation [Documentation]. [https://huggingface.co/docs/transformers/en/model\\_doc/roberta](https://huggingface.co/docs/transformers/en/model_doc/roberta)
7. Cardiff NLP (n.d.). Twitter RoBERTa Base for Sentiment Analysis [Model]. <https://huggingface.co/cardiffnlp/twitter-roberta-base-sentiment>
8. Hugging Face (n.d.). Transformers Pipelines Documentation [Documentation]. [https://huggingface.co/docs/transformers/en/main\\_classes/pipelines](https://huggingface.co/docs/transformers/en/main_classes/pipelines)  
Hugging Face (n.d.). DistilBERT Model Documentation [Documentation]. [https://huggingface.co/docs/transformers/en/model\\_doc/distilbert](https://huggingface.co/docs/transformers/en/model_doc/distilbert)
9. Hugging Face (n.d.). DistilBERT Base Uncased Fine-Tuned for SST-2 [Model]. <https://huggingface.co/distilbert/distilbert-base-uncased-finetuned-sst-2-english>